

Lab 2

Bài 1:

1) Vocabulary = { the, cat, eats, fish, like, dog, meat }
→ $|V| = 7$

2) token = 12.

$$3) P(\text{the}) = \frac{3}{12} = \frac{1}{4}$$

$$P(\text{cat}) = \frac{1}{6}$$

$$P(\text{fish}) = \frac{1}{6}$$

$$P(\text{dog}) = \frac{1}{12}$$

4)

$$\sum_w P(w) = \frac{1}{4} + \frac{1}{6} + \frac{1}{12} + \frac{1}{12} + \frac{1}{6} + \frac{1}{12} + \frac{1}{6} = 1$$

Bài 2:

$$P(\text{cat} | \text{the}) = \frac{2}{3}$$

$$P(\text{dog} | \text{the}) = \frac{1}{3}$$

$$P(\text{eats} | \text{cat}) = \frac{2}{3}$$

$$P(\text{likes} | \text{cat}) = \frac{1}{2}$$

Tổng số lần xuất hiện của tất cả các bigram bắt đầu bằng từ "the" chính = tổng số lần từ "the" xuất hiện trong Corpus: $\sum_w \text{Count}(\text{"the"}, w) = \text{Count}(\text{"the"})$

Do đó, khi lấy tổng xác suất có thể trên toàn bộ từ vựng V: $\sum_{w \in V} P(w | \text{the}) = \frac{\sum_{w \in V} \text{Count}(\text{"the"}, w)}{\text{Count}(\text{"the"})} = 1$

Bài 3:

$$\frac{P(\text{the}) \cdot P(\text{cat} | \text{the}) \cdot P(\text{eats} | \text{cat}) \cdot P(\text{fish} | \text{eats})}{P(\text{the}) \cdot P(\text{cat} | \text{the}) \cdot P(\text{eats} | \text{cat}) \cdot P(\text{fish} | \text{eats})} = \frac{1}{4} \cdot \frac{2}{3} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{24}$$

Nếu thêm từ 1 từ vào câu, xác suất của cả câu ko thể tăng. Vì mọi xác suất có thể đều nằm ở đoạn $[0, 1]$. Khi thêm 1 từ mới w_{n+1} vào câu, xác suất câu mới sẽ là:

$$P(w_1, \dots, w_{n+1}) = P(w_1, \dots, w_n) \cdot P(w_{n+1} | w_n)$$

Vì $0 \leq P(w_{n+1} | w_n) \leq 1$, và nhân thêm 1 số ≤ 1 luôn làm giảm giá trị tích nhỏ hơn $\alpha = \text{ban đầu}$.

Bài 4:

Câu S1 có xác suất cao hơn.

9. Bài tập suy luận trước khi smoothing

1) $\text{Count}(\text{study AI}) = 0$

2)

$$P(\text{AI} | \text{study}) = \frac{\text{Count}(\text{study AI})}{\text{Count}(\text{study})} = \frac{0}{1} = 0$$

3) Xác suất của cả câu sẽ = 0. Vì xác suất câu theo mô hình để tính = tích các câu xác suất thành phần, chỉ cần 1 bigram có xác suất = 0 thì toàn bộ tích sẽ triệt tiêu về 0.

4) Không. xác suất = 0 chỉ phản ánh sự hạn chế của dữ liệu, chứ ko phản ánh bản chất của ngôn ngữ.

11. Bài tập tính smoothing

$$C(\text{cat}) = 10, V = 5$$

$$\begin{aligned} \Rightarrow P_{\text{Laplace}}(\text{cats} / \text{cat}) &= \frac{C(\text{cat}, \text{cat}) + 1}{C(\text{cat}) + V} \\ &= \frac{0 + 1}{10 + 5} = \frac{1}{15} \end{aligned}$$

$$C(\text{cat}, \text{cats}) = 3$$

$$\Rightarrow P_{\text{Laplace}}(\text{cats} / \text{cat}) = \frac{3 + 1}{10 + 5} = \frac{4}{15}$$

Kết quả:

- Các bigram chứa từ gặp ($C = 0$) sẽ nâng từ 0 lên số dương (> 0)
- Các bigram từ xuất hiện ($C > 0$) đều bị giảm nhẹ xác suất so với MLE

18. Perplexity

$$P(W) = P(w_1) P(w_2|w_1) P(w_3|w_2) = 0,5 \cdot 0,25 \cdot 0,5 = \frac{1}{16}$$

$$PP(W) = P(W)^{-1/3} = 2^{\frac{1}{3}} \sqrt[3]{2}$$

$$P'(W) = 0,5 \cdot 0,1 \cdot 0,5 = \frac{1}{40}$$

$$PP'(W) = P'(W)^{-1/3} = 40^{\frac{1}{3}} \sqrt[3]{40}$$

CRABIT

- Bản chất nghịch đảo ~~PP(w)~~:

- $PP(w)$ là tập nhân của các nghịch đảo

$$\underline{P(w_i / \dots)}$$